Reporte de progreso — Proyecto 4chan-NLP-Dashboard

Avance hacia la analítica de narrativas y el chatbot

12-11-26

Reporte de progreso

Objetivo original. Entrenar clasificadores de marco narrativo y toxicidad sobre *Raiders of the Lost Kek* (4chan `/pol/`, 2016–2019), aplicarlos a datos recientes obtenidos vía 4plebs y comparar la evolución del tablero en relación con eventos externos como Pizzagate, la emergencia de QAnon y Christchurch. El producto es una aplicación de analítica para científicos sociales y analistas políticos, con un **chatbot inteligente** como componente más importante.

Estado general. El proyecto completó la base de datos, limpieza y anotación humana, y la capa de analítica compartida (`keklab.analytics`) ya alimenta un backend HTTP (FastAPI), un panel web (HTML/JS + Plotly) y un chatbot por herramientas. Todavía **no hay clasificadores entrenados ni L1 aplicado al corpus**, por lo que las cuotas de marcos y toxicidad del panel se presentan como volumen. La fase actual es conectar el modelo con el corpus.

Decisiones tomadas

Datos y comparabilidad

Decisión	Valor adoptado
Fuente histórica	ROTLK `/pol/` 2016–2019; lectura en sitio del `.tar.zst`, sin copiarlo ni extraerlo.
Fuente reciente	API de 4plebs, últimos 24 meses, con el mismo esquema y codebook.
Períodos	2016-2019 vs 2020 en adelante, para comparar con los mismos clasificadores.

Decisión	Valor adoptado
Unidad de análisis	Post; agrupación por hilo. Split por `thread_id` para evitar fuga entre OP y respuestas.
Partición	60/20/20, semilla 13; test congelado y hasheado antes de entrenar.
Eventos externos	Pizzagate, QAnon y Christchurch como hitos de comparación, no como etiquetas del modelo.

Anotación y etiquetas

Decisión	Valor adoptado
Oro humano	200 posts: 190 aleatorios + 10 dirigidos; los dirigidos solo entrenan/calibran.
Interfaz	CLI de terminal; sin interfaz web ni herramienta externa.
Unidad de clasificación	Solo el post objetivo: sin OP, quotes, `subject` ni estrato de muestreo. Si no se entiende, `unclear`.
Plata	5.000 posts aleatorios, semilla 17, etiquetados por `Qwen3-8B-Q4_K_M`; se confía en la plata sin revisión humana.
Rol del oro	Diagnóstico externo del maestro; no entrena, corrige ni bloquea la plata.

Taxonomía de clasificación

Reglas que gobiernan la taxonomía:

Regla	Decisión
Estructura	16 marcos finos binarios multi-label; 7 cabezas gruesas derivadas.
Toxicidad	Escala ordinal `0-3`, independiente de los marcos.
`none` / `unclear`	Exclusivos con cualquier otro marco y entre sí.
Prejuicio específico	Se añadió `rusophobia` y `sinophobia` por prevalencia en el corpus

Regla	Decisión
Género y sexualidad	Se optó por mantener`transphobia`, `homophobia` y `misogyny` como ejes independientes.

Cada marco y la toxicidad son ejes separados. Durante la clasificación se observó correlación alta entre toxicidad 3 y glorificación de la violencia. Se optó por mantener ambos aunque se superpongan, ya que remiten a categorías semánticas distintas.

#	Marco	Definición
1	`conspiracy`	Afirmación de un plan o coordinación secreta de élites, agencias o grupos.
2	`ethnonationalism`	Pureza, superioridad o jerarquía nacional/étnica genérica **no** cubierta por una etiqueta más específica.
3	`racism`	Prejuicio, slur, segregación o jerarquía racial/étnica **no** cubierta por una etiqueta de grupo específica.
4	`antisemitism`	Hostilidad, tropos o prejuicio contra judíos.
5	`islamophobia`	Hostilidad o prejuicio contra musulmanes o el islam.
6	`rusophobia`	Hostilidad o prejuicio contra rusos o Rusia.
7	`sinophobia`	Hostilidad o prejuicio contra chinos o China.
8	`misogyny`	Hostilidad, desprecio u objetificación hacia las mujeres como clase; inferioridad femenina u oposición a los derechos de las mujeres.
9	`transphobia`	Hostilidad, burla o prejuicio contra personas trans o negación de su identidad.

#	Marco	Definición
10	`homophobia`	Hostilidad, burla o prejuicio contra personas gays o lesbianas.
11	`institutional_distrust`	Desconfianza generalizada hacia Estado, medios, academia o elecciones, sin afirmación conspirativa explícita.
12	`violence_glorification`	Elogio, celebración o incitación a la violencia (no mera discusión o noticia).
13	`accelerationism`	Deseo de acelerar el colapso, el conflicto o la desestabilización.
14	`meta_topic`	Meta-discusión del tablero, moderación, raids, cultura online.
15	`none`	Ningún marco reconocible.
16	`unclear`	Contexto insuficiente, truncamiento o ambigüedad genuina.

Toxicidad

Nivel	Definición
`0`	Neutral, sin toxicidad.
`1`	Insulto leve, hostilidad o edgy sin agresión grave.
`2`	Deshumanización explícita, slur, acoso u odio dirigido a un grupo.
`3`	Amenaza, incitación o celebración de violencia contra personas reales.

Evaluación y modelado

Decisión	Valor adoptado
Expresiones regulares	El uso de regex es necesario para limpiar los posts de código html, citas a otros posts y otros artefactos que obstaculizan el procesamiento de lenguaje
Modelos comparados	TF-IDF + LR, BoW + SVM, embeddings + lineal, BERT/RoBERTa, Laya, GLiClass y GLiNER.
Métricas	P/R/F1 por clase, macro y micro; bootstrap por hilo. Toxicidad: kappa cuadrática, MAE y matriz de confusión.
Límite de la plata	La tabla principal mide imitación del maestro, no verdad; el oro de 200 posts es la referencia externa.

Producto y alcance

Decisión	Valor adoptado
Producto	Aplicación de analítica para científicos sociales y analistas políticos.
Chatbot	Componente más importante; *tool calling* sobre el backend analítico (`consultar`, `graficar`, `clasificar`, `resumir`, `extraer_entidades`).
Dashboard	Exploración de marcos, toxicidad y series temporales con hitos históricos.
Comparación temporal	Histórico vs reciente con los mismos clasificadores y ventanas comparables.
Extracción estructurada	Tópicos y entidades con Laya/Gleaner/GLiNER, integrados al dashboard y al chatbot.
Orden de construcción	Datos → clasificador → comparación temporal → backend → dashboard → chatbot.

Resumen de avance

Componente	Estado	Foco inmediato
Corpus histórico ROTLK	Listo	L0 en disco externo: 134,5 M posts en Parquet mensual.
Corpus reciente 4plebs	Parcial	Descargar y validar la ventana de 24 meses.
Anotación humana	Listo (piloto)	Ampliar si se busca el modelo completo.
Clasificadores de marco y toxicidad	Iniciado	Plata de 5.000 posts y evaluación E0/E2.
Comparación temporal	No iniciado	Datos recientes + modelo + línea de eventos.
Backend analítico	Listo	`keklab.analytics`: filtros, cuotas, series, procedencia.
Dashboard	En producción (web)	Backend FastAPI + front servido desde `web/`; 7 secciones; faltan cuotas de marcos hasta que haya L1.
Chatbot	En curso	5 herramientas sobre el backend; falta el LLM que enrute y la suite E5.
Extracción estructurada	No iniciado	Integración de Laya/Gleaner/GLiNER.
Interfaz	FastAPI + HTML/JS servido desde `web/` con Plotly local; filtros en la URL.	El backend no cambia: los tres productos (dashboard, chatbot, CLI) consumen `keklab.analytics`.

En una frase: **la infraestructura, el corpus, el oro, el backend y el panel ya existen; falta el modelo aplicado al corpus (L1) y la ventana reciente.**

Obstáculos

Obstáculo	Efecto	Cómo se aborda
Escala y acceso a ROTLK	El dump es demasiado grande para copiarlo.	Lectura en sitio y muestreo por streaming; resuelto.

Obstáculo	Efecto	Cómo se aborda
Datos recientes incompletos	Sin 4plebs reciente no hay comparación temporal.	Descargar y validar la ventana de 24 meses.
Marcos raros y pocos positivos	Un modelo de 16 marcos no se aprende con 200 posts.	Muestra plata de 5.000, muestreo dirigido y reporte descriptivo.
Sesgo del LLM en la plata	La plata hereda errores y sesgos del maestro.	No llamarla oro; diagnóstico externo con el oro de 200.
Un solo anotador humano	No hay acuerdo inter-anotador.	Self test-retest pendiente y limitación documentada.
Cómputo limitado	GPU de 8 GB y sin API externa para millones de textos.	Modelos clásicos/encoders a escala; LLM local para etiquetado y chatbot.
Producto sin backend	Dashboard y chatbot dependen de consultas y series.	Resuelto: `keklab.analytics` es la fuente única.

Hoja de ruta

Fase	Objetivo	Entregable
0. Base (hecha)	Infraestructura, corpus histórico y oro.	Pipeline, 200 posts anotados, protocolo y tests.
1. Datos recientes	Completar la ventana de 24 meses de 4plebs.	Corpus reciente auditado y comparable.
2. Plata y primer clasificador	Etiquetar 5.000 posts con el LLM y entrenar el *baseline*.	Plata confiada, E0/E2 y métricas por cabeza.
3. Escalado	Comparar clásicos, BERT, Laya, GLiClass y GLiNER.	Modelo aplicable a volúmenes grandes.
4. Comparación temporal	Aplicar el modelo a histórico y reciente.	E4 con series y eventos.
5. Backend analítico (hecha)	Consultas, agregados y series para la UI.	`keklab.analytics` + CLI.
6. Dashboard (MVP hecha)	Exploración visual para analistas.	7 secciones con volumen; cuotas cuando haya L1.

Fase	Objetivo	Entregable
7. Chatbot (en curso)	*Tool calling* sobre el backend.	5 herramientas; falta el LLM que enrute y la suite E5.
8. Extracción estructurada	Tópicos y entidades por marco/período.	E6 integrado al dashboard/chatbot.

Conclusión

La base técnica, el corpus histórico, el esquema de anotación, el backend analítico y el panel están resueltos. Lo que falta es **conectar el modelo con el corpus**: hasta que exista L1, las cuotas de marcos y toxicidad del panel son volumen, no prevalencia. La ruta crítica queda así: datos recientes $\rightarrow$ clasificador $\rightarrow$ L1 $\rightarrow$ comparación temporal, con el dashboard y el chatbot ya listos para mostrar lo que se les dé. La única decisión de alcance que sigue abierta es si la comparación histórica contra reciente entra antes o después de la extracción estructurada de tópicos y entidades.