Reporte de progreso — Proyecto 4chan-NLP-Dashboard

Avance hacia la analítica de narrativas y el chatbot

10-11-2026

Reporte de progreso

Objetivo original. Entrenar clasificadores de marco narrativo y toxicidad sobre *Raiders of the Lost Kek* (4chan `/pol/`, 2016–2019), aplicarlos a datos recientes obtenidos vía 4plebs y comparar la evolución del tablero en relación con eventos externos como Pizzagate, la emergencia de QAnon y Christchurch. El producto es una aplicación de analítica para científicos sociales y analistas políticos, con un **chatbot inteligente** como componente más importante.

Estado general. El proyecto completó la base de datos, limpieza y anotación humana. Todavía **no hay clasificadores entrenados, dashboard ni chatbot**. La fase actual es la plataforma sobre la que se construirán esos tres productos.

1. Qué debe entregar el proyecto

Componente	Papel en el objetivo
Corpus histórico y reciente	Base comparable para medir evolución.
Clasificadores de marco y toxicidad	Convierten texto en narrativas y niveles de toxicidad.
Comparación temporal	Responde cómo cambió `/pol/` entre 2016–2019 y el presente.
Dashboard analítico	Permite explorar distribuciones, series y eventos.
Chatbot con *tool calling*	Interfaz principal para analistas; debe consultar, graficar y explicar.
Extracción estructurada	Tópicos y entidades por marco/período; apoya dashboard y chatbot.

2. Resumen de avance

Componente	Estado	Foco inmediato
Corpus histórico ROTLK	Listo	—
Corpus reciente 4plebs	Parcial	Descargar y validar la ventana de 24 meses.
Anotación humana	Listo (piloto)	Ampliar si se busca el modelo completo.
Clasificadores de marco y toxicidad	No iniciado	Baseline y evaluación E0/E2.
Comparación temporal	No iniciado	Datos recientes + modelo + línea de eventos.
Dashboard	No iniciado	Backend analítico y UI.
Chatbot	No iniciado	Tool calling y suite E5.
Extracción estructurada	No iniciado	Integración de Laya/Gleaner/GLiNER.

En una frase: **la infraestructura y el oro están listos; el producto analítico y el chatbot todavía no.**

3. Progreso por componente

3.1 Datos históricos y recientes

El corpus histórico se lee directamente del dump de ROTLK, sin copiarlo ni extraerlo: **3,397,911 hilos y 134,529,233 posts**. Sobre ese corpus se construyó una muestra de **200 posts y 200 hilos** de `/pol/`, ventana `2017-11-11T10:15:36Z` → `2019-11-01T10:15:36Z`, con **190 aleatorios + 10 dirigidos** para enriquecer marcos poco frecuentes.

La capa de ingesta incluye limpieza de marcas de 4chan, normalización Unicode, extracción de citas, deduplicación y features de hilo. El cliente de 4plebs ya pagina, cachea, reintenta y resuelve el bloqueo TLS con `curl`; el *smoke test* de índice, hilo y búsqueda funcionó. Sin embargo, **la tanda reciente de 24 meses todavía no se descargó ni se validó a escala**.

3.2 Anotación humana

El piloto tiene **200 registros de oro**. La composición es 52 anotaciones originales más 148 propuestas de un agente de lenguaje revisadas por una persona: **124 aceptadas, 24 editadas, 0 rechazadas y 0 saltadas**. El acuerdo propuesta-final fue Jaccard 0.898; la toxicidad coincidió exactamente en 94.6 % de los casos (MAE 0.054).

La taxonomía quedó en **16 marcos finos y 7 cabezas gruesas**, con toxicidad ordinal `0`–`3`, reglas de exclusividad para `none`/`unclear` y definiciones para prejuicios específicos. El codebook, el protocolo de evaluación y la partición 120/40/40 por hilo están documentados y la suite pasa con **136 pruebas**.

Este es el activo más maduro del proyecto, pero también el cuello de botella: 200 posts alcanzan para empezar, no para cubrir todos los marcos raros.

3.3 Clasificadores de marco y toxicidad

No se entrenó ningún modelo todavía. Tampoco se ejecutaron E0 (crudo vs saneado) ni E2 (TF-IDF + regresión logística, BoW + SVM, embeddings). El piloto muestra que el tamaño actual permite un primer *baseline* en las cabezas con más soporte, pero no el modelo completo de 16 marcos. La ruta prevista es:

1. entrenar un *baseline* sobre las etiquetas con soporte suficiente;
2. usar el LLM como pre-anotador para generar etiquetas "plata" a escala;
3. validar los modelos clásicos contra el oro.

El flujo de pre-anotación con IA ya está listo y tiene un handoff para un agente relevo, incluido el prompt versionado. Eso permite escalar el etiquetado sin llamar a una API desde `keklab`.

3.4 Comparación temporal

No iniciada. Para responder a Pizzagate, QAnon y Christchurch hacen falta tres piezas que todavía no están juntas:

- la tanda reciente de 4plebs, con el mismo esquema y la misma limpieza;
- un clasificador estable aplicado a ambos períodos;
- una línea de tiempo de eventos externos y ventanas comparables.

La infraestructura de `period` (`hist_2016_2019` vs `recent_2020_plus`) ya existe; falta producir los datos y el modelo.

3.5 Dashboard analítico

No iniciado. Solo están definidos los servicios compartidos que deberían alimentar la UI. El dashboard debe mostrar distribución de marcos, niveles de toxicidad, series temporales con hitos y comparación histórica vs reciente. La tecnología de UI sigue pendiente de decisión.

3.6 Chatbot

No iniciado, y es la parte más importante del proyecto. Las herramientas objetivo están definidas: `consultar`, `graficar`, `clasificar`, `resumir` y `extraer_entidades`. El chatbot depende de que existan:

1. corpus reciente;
2. clasificadores aplicables;
3. backend analítico con consultas y series;
4. suite de evaluación E5 (~25 preguntas con *tool calling* y gráficos).

Sin esas piezas, un chatbot sería una interfaz sin datos confiables detrás.

3.7 Extracción estructurada

No iniciada. El plan original incluye tópicos y entidades por marco y período, con Laya y Gleaner/GLiNER como modelos candidatos. Esto alimenta tanto el dashboard como el chatbot (por ejemplo, "mostrame entidades y narrativas alrededor de Christchurch"). Todavía no hay integración ni evaluación.

4. Obstáculos

Obstáculo	Efecto	Cómo se aborda
Escala y acceso a ROTLK	El dump es demasiado grande para copiarlo.	Lectura en sitio y muestreo por streaming; ya resuelto.
Datos recientes incompletos	Sin 4plebs reciente no hay comparación temporal.	Ejecutar y validar la ventana de 24 meses.
Marcos raros y pocos positivos	Un modelo de 16 marcos no se aprende con 200 posts.	Ampliar oro, muestreo dirigido y etiquetas plata.
Cómputo limitado	GPU de 8 GB y sin API externa de LLM para millones de textos.	Encoders y modelos clásicos para volumen; LLM solo para etiquetado y chatbot.
Un solo anotador	No hay acuerdo inter-anotador.	Self test-retest pendiente y limitación documentada.
Producto aún sin backend	Dashboard y chatbot no pueden construirse antes de las consultas.	Priorizar corpus → clasificador → backend analítico.
Alineación de eventos	Pizzagate, QAnon y Christchurch no coinciden con ventanas triviales.	Definir línea de tiempo y ventanas antes de comparar.

5. Hoja de ruta

Fase	Objetivo	Entregable
0. Base (hecha)	Infraestructura, corpus histórico y oro.	Pipeline, 200 posts anotados, protocolo y tests.
1. Datos recientes	Completar la ventana de 24 meses de 4plebs.	Corpus reciente auditado y comparable.
2. Primer clasificador	Entrenar y evaluar un *baseline* de marcos y toxicidad.	E0/E2 con métricas por cabeza.
3. Escalado	Generar etiquetas plata con LLM y ampliar el entrenamiento.	Modelo aplicable a volúmenes grandes.
4. Comparación temporal	Aplicar el modelo a histórico y reciente.	E4 con series y eventos.
5. Backend analítico	Consultas, agregados y series para la UI.	API/servicios compartidos.

Fase	Objetivo	Entregable
6. Dashboard	Exploración visual para analistas.	MVP con distribución, toxicidad y tiempo.
7. Chatbot	*Tool calling* sobre el backend.	Chatbot + suite E5.
8. Extracción estructurada	Tópicos y entidades por marco/período.	E6 integrado al dashboard/chatbot.

Prioridad inmediata: cerrar la tanda reciente de 4plebs, entrenar el primer *baseline* y ejecutar el self test-retest. Sin esas tres piezas no se puede empezar la comparación temporal ni darle datos confiables al chatbot.

6. Conclusión

El proyecto tiene una base sólida: corpus histórico, limpieza, anotación humana, protocolo y flujo de pre-anotación. Pero el avance debe medirse contra el producto original, y ese producto todavía no existe: faltan los clasificadores, la comparación temporal, el dashboard y el chatbot.

El riesgo principal ya no es de infraestructura sino de **alcance y secuencia**. La ruta crítica es: datos recientes → primer clasificador → comparación temporal → backend analítico → dashboard → chatbot. El chatbot es la meta principal y debe orientar las prioridades; por eso conviene no seguir invirtiendo en detalles internos del codebook antes de tener un modelo que produzca las series que el chatbot necesita explicar.