Reporte de progreso — Proyecto 4chan-NLP-Dashboard

Avance hacia la analítica de narrativas y el chatbot

10-11-2026

Reporte de progreso

Objetivo original. Entrenar clasificadores de marco narrativo y toxicidad sobre *Raiders of the Lost Kek* (4chan `/pol/`, 2016–2019), aplicarlos a datos recientes obtenidos vía 4plebs y comparar la evolución del tablero en relación con eventos externos como Pizzagate, la emergencia de QAnon y Christchurch. El producto es una aplicación de analítica para científicos sociales y analistas políticos, con un **chatbot inteligente** como componente más importante.

Estado general. El proyecto completó la base de datos, limpieza y anotación humana. Todavía **no hay clasificadores entrenados, dashboard ni chatbot**. La fase actual es la plataforma sobre la que se construirán esos tres productos: el plan de etiquetado plata y de comparación de modelos ya está definido.

Decisiones tomadas

Datos y comparabilidad

Decisión	Valor adoptado
Fuente histórica	ROTLK `/pol/` 2016–2019; lectura en sitio del `.tar.zst`, sin copiarlo ni extraerlo.
Fuente reciente	API de 4plebs, últimos 24 meses, con el mismo esquema y codebook.
Períodos	`hist_2016_2019` vs `recent_2020_plus`, para comparar con los mismos clasificadores.
Unidad de análisis	Post; agrupación por hilo. Split por `thread_id` para evitar fuga entre OP y respuestas.
Partición	60/20/20, semilla 13; test congelado y hasheado antes de entrenar.
Eventos externos	Pizzagate, QAnon y Christchurch como hitos de comparación, no como etiquetas del modelo.

Anotación y etiquetas

Decisión	Valor adoptado
Oro humano	200 posts: 190 aleatorios + 10 dirigidos; los dirigidos solo entrenan/calibran.
Interfaz	CLI de terminal; sin interfaz web ni herramienta externa.

Decisión	Valor adoptado
IA sobre el oro	Solo propone; nunca es oro sin revisión humana. Generación file-based, sin llamar a una API desde `keklab`.
Texto permitido	Solo el post objetivo: sin OP, quotes, `subject` ni estrato de muestreo. Si no se entiende, `unclear`.
Acuerdo	Self test-retest del ~20 % (40 posts); mide consistencia intra-anotador, no acuerdo inter-anotador.
Plata	5.000 posts aleatorios, semilla 17, etiquetados por `Qwen3-8B-Q4_K_M`; se confía en la plata sin revisión humana.
Rol del oro	Diagnóstico externo del maestro; no entrena, corrige ni bloquea la plata.

Taxonomía de clasificación

Cada marco y la toxicidad son ejes separados. Durante la clasificación se observó correlación alta entre toxicidad 3 y glorificación de la violencia. Se optó por mantener ambos aunque se superpongan, porque remiten a categorías semánticas distintas.

#	Marco	Definición
1	`conspiracy`	Afirmación de un plan o coordinación secreta de élites, agencias o grupos.
2	`ethnonationalism`	Pureza, superioridad o jerarquía nacional/étnica genérica **no** cubierta por una etiqueta más específica.
3	`racism`	Prejuicio, slur, segregación o jerarquía racial/étnica **no** cubierta por una etiqueta de grupo específica.
4	`antisemitism`	Hostilidad, tropos o prejuicio contra judíos.
5	`islamophobia`	Hostilidad o prejuicio contra musulmanes o el islam.
6	`rusophobia`	Hostilidad o prejuicio contra rusos o Rusia.
7	`sinophobia`	Hostilidad o prejuicio contra chinos o China.
8	`misogyny`	Hostilidad, desprecio u objetificación hacia las mujeres como clase; inferioridad femenina u oposición a los derechos de las mujeres.
9	`transphobia`	Hostilidad, burla o prejuicio contra personas trans o negación de su identidad.

#	Marco	Definición
10	homophobia	Hostilidad, burla o prejuicio contra personas gays o lesbianas.
11	institutional_distrust	Desconfianza generalizada hacia Estado, medios, academia o elecciones, sin afirmación conspirativa explícita.
12	violence_glorification	Elogio, celebración o incitación a la violencia (no mera discusión o noticia).
13	accelerationism	Deseo de acelerar el colapso, el conflicto o la desestabilización.
14	meta_topic	Meta-discusión del tablero, moderación, raids, cultura online.
15	none	Ningún marco reconocible.
16	unclear	Contexto insuficiente, truncamiento o ambigüedad genuina.

Reglas que gobiernan la taxonomía:

Regla	Decisión
Estructura	16 marcos finos binarios multi-label; 7 cabezas gruesas derivadas.
Toxicidad	Escala ordinal 0–3, independiente de los marcos.
none / unclear	Exclusivos con cualquier otro marco y entre sí.
Prejuicio específico	Reemplaza a ethnonationalism / racism genéricos.
Género y sexualidad	transphobia y homophobia son ejes independientes de misogyny.
Superposición	violence_glorification y toxicidad 3 se conservan como categorías distintas.
Retiros	eugenics, ableism y la cabeza eugenics_ableism se retiraron; los artefactos viejos se normalizan al cargar.
Versiones	Codebook v0.2 y prompt v2; el hash del prompt cubre plantilla y menús generados.

Toxicidad

Nivel	Definición
0	Neutral, sin toxicidad.
1	Insulto leve, hostilidad o edgy sin agresión grave.
2	Deshumanización explícita, slur, acoso u odio dirigido a un grupo.

Nivel	Definición
3	Amenaza, incitación o celebración de violencia contra personas reales.

Evaluación y modelado

Decisión	Valor adoptado
Soporte mínimo	≥30 positivos en train y ≥5 en test por cabeza/marco; si no se cumple, se reporta como descriptivo.
E0	`text_raw` vs `text_clean`; la limpieza solo se adopta si mejora de forma consistente en dev.
Modelos comparados	TF-IDF + LR, BoW + SVM, embeddings + lineal, BERT/RoBERTa, Laya, GLiClass y GLiNER.
Ajuste	Hiperparámetros en dev; una sola evaluación final en test.
Métricas	P/R/F1 por clase, macro y micro; bootstrap por hilo. Toxicidad: kappa cuadrática, MAE y matriz de confusión.
Límite de la plata	La tabla principal mide imitación del maestro, no verdad; el oro de 200 posts es la referencia externa.
Cómputo	GPU de 8 GB: encoders y modelos clásicos para volumen; LLM local para etiquetado y chatbot.

Producto y alcance

Decisión	Valor adoptado
Producto	Aplicación de analítica para científicos sociales y analistas políticos.
Chatbot	Componente más importante; *tool calling* sobre el backend analítico (`consultar`, `graficar`, `clasificar`, `resumir`, `extraer_entidades`).
Dashboard	Exploración de marcos, toxicidad y series temporales con hitos históricos.
Comparación temporal	Histórico vs reciente con los mismos clasificadores y ventanas comparables.
Extracción estructurada	Tópicos y entidades con Laya/Gleaner/GLiNER, integrados al dashboard y al chatbot.
Orden de construcción	Datos → clasificador → comparación temporal → backend → dashboard → chatbot.

Resumen de avance

Componente	Estado	Foco inmediato
Corpus histórico ROTLK	Listo	—
Corpus reciente 4plebs	Parcial	Descargar y validar la ventana de 24 meses.

Componente	Estado	Foco inmediato
Anotación humana	Listo (piloto)	Ampliar si se busca el modelo completo.
Clasificadores de marco y toxicidad	Iniciado	Plata de 5.000 posts y evaluación E0/E2.
Comparación temporal	No iniciado	Datos recientes + modelo + línea de eventos.
Dashboard	No iniciado	Backend analítico y UI.
Chatbot	No iniciado	Tool calling y suite E5.
Extracción estructurada	No iniciado	Integración de Laya/Gleaner/GLiNER.

En una frase: **la infraestructura, el oro y el plan de modelado están listos; el producto analítico y el chatbot todavía no.**

Obstáculos

Obstáculo	Efecto	Cómo se aborda
Escala y acceso a ROTLK	El dump es demasiado grande para copiarlo.	Lectura en sitio y muestreo por streaming; resuelto.
Datos recientes incompletos	Sin 4plebs reciente no hay comparación temporal.	Descargar y validar la ventana de 24 meses.
Marcos raros y pocos positivos	Un modelo de 16 marcos no se aprende con 200 posts.	Muestra plata de 5.000, muestreo dirigido y reporte descriptivo.
Sesgo del LLM en la plata	La plata hereda errores y sesgos del maestro.	No llamarla oro; diagnóstico externo con el oro de 200.
Un solo anotador humano	No hay acuerdo inter-anotador.	Self test-retest pendiente y limitación documentada.
Cómputo limitado	GPU de 8 GB y sin API externa para millones de textos.	Modelos clásicos/encoders a escala; LLM local para etiquetado y chatbot.
Producto sin backend	Dashboard y chatbot dependen de consultas y series.	Priorizar corpus → clasificador → backend analítico.

Hoja de ruta

Fase	Objetivo	Entregable
0. Base (hecha)	Infraestructura, corpus histórico y oro.	Pipeline, 200 posts anotados, protocolo y tests.
1. Datos recientes	Completar la ventana de 24 meses de 4plebs.	Corpus reciente auditado y comparable.
2. Plata y primer clasificador	Etiquetar 5.000 posts con el LLM y entrenar el *baseline*.	Plata confiada, E0/E2 y métricas por cabeza.
3. Escalado	Comparar clásicos, BERT, Laya, GLiClass y GLiNER.	Modelo aplicable a volúmenes grandes.
4. Comparación temporal	Aplicar el modelo a histórico y reciente.	E4 con series y eventos.

Fase	Objetivo	Entregable
5. Backend analítico	Consultas, agregados y series para la UI.	API/servicios compartidos.
6. Dashboard	Exploración visual para analistas.	MVP con distribución, toxicidad y tiempo.
7. Chatbot	*Tool calling* sobre el backend.	Chatbot + suite E5.
8. Extracción estructurada	Tópicos y entidades por marco/período.	E6 integrado al dashboard/chatbot.

Conclusión

La base técnica, el corpus histórico y el esquema de anotación están resueltos. Las decisiones pendientes ya no son de infraestructura sino de **alcance y secuencia**: la plata de 5.000 posts permite entrenar y comparar modelos, pero el producto original —comparación temporal, dashboard y chatbot— todavía no existe. La ruta crítica es datos recientes → clasificador → comparación → backend → dashboard → chatbot, y el chatbot debe orientar las prioridades.